

计算机视觉 HW2 汇报讲稿

各位老师好，我是陈家龙，学号 24300980041。今天汇报的是计算机视觉 HW2 的三项任务，整体包括宠物品种分类、场景目标检测与视频跟踪，以及基于 U-Net 的语义分割。我的汇报会按照目录中的三个部分展开：第一部分介绍预训练 CNN 微调和注意力机制，第二部分介绍 YOLOv8n 在 VisDrone 和校园视频上的检测跟踪，第三部分介绍从零实现 U-Net 以及三种损失函数的比较。

首先是任务一。这个任务使用 Oxford-IIIT Pet 数据集做 37 类宠物品种分类。这里我想先说明预训练和本实验训练的区别。ImageNet 预训练发生在本实验之前，使用的是 ImageNet 的大规模图像和 1000 类标签，它的作用是让 ResNet-18 的卷积主干先学到比较通用的视觉特征，比如边缘、纹理、局部形状和高层语义。到了本作业中，我把最后的 fc 分类层替换成 37 类输出，并在 Oxford-IIIT Pet 上训练。也就是说，本实验真正训练的是新的分类头，以及用较小学习率微调的预训练主干。

为了让这两部分参数以不同速度学习，我在代码中做了参数分组。fc 层从随机初始化开始，需要较大的学习率快速适应新的 37 类宠物分类，所以 classifier learning rate 设置为 0.001；主干网络已经有 ImageNet 表示，如果更新太大反而容易破坏已有特征，所以 backbone learning rate 设置为 0.0001。训练入口由 main.py 读取 YAML 配置，依次完成数据加载、模型构建、损失函数、优化器、学习率调度和评估，并把 history JSON、summary 和图像结果保存下来。

接下来是注意力机制。本实验实现的是 SE-block。它的思想是让网络在特征通道维度上做一次重新加权。具体来说，先对每个通道做全局平均池化，把 $C \times H \times W$ 的特征图压缩成 $C \times 1 \times 1$ 的通道统计量；然后经过 FC、ReLU、FC 和 Sigmoid 得到每个通道的权重；最后把这些权重乘回原特征图。这样模型就能增强对宠物品种有帮助的毛色、纹理和局部形状，同时抑制无关背景。在我的实现里，SE-block 被插入到第二个 BatchNorm 之后、残差连接相加之前。由于新增的 SE 参数和最终分类头无法直接从原始 ResNet-18 中加载，所以只有名称和形状匹配的部分继承 ImageNet 权重，其余参数随机初始化。

从任务一结果看，预训练的收益最明显。Baseline 的测试准确率约为 0.8801，而从头训练的 scratch 版本只有 0.4424，差距接近 43 个百分点，说明这种中小规模细粒度分类任务非常依赖预训练表示。超参数搜索中，backbone_lr 为

0.0001、classifier_lr 为 0.001 时效果最好，测试准确率约 0.8820。SE-block 版本测试准确率为 0.8621，低于 baseline。我认为主要原因是 SE-block 增加了随机初始化参数，同时注意力模型没有单独重新做学习率搜索，所以它完成了注意力机制引入，但在当前设置下没有带来额外提升。

第二部分是目标检测、跟踪与越线计数。这个任务使用 VisDrone 数据集训练 YOLOv8n。VisDrone 包含 pedestrian、people、bicycle、car、van、truck、tricycle、awning-tricycle、bus 和 motor 等类别。选择 YOLOv8n 的原因是它参数量小、推理速度快，更适合在本机显存条件下完成完整训练和视频应用流程。训练后的 best.pt 被用于自采校园道路视频，输出检测框、类别、置信度和 Tracking ID，然后进一步做遮挡分析和越线计数。

训练设置上，我使用 50 个 epoch，输入尺寸 640，batch 为 4，workers 为 0。这是因为本地环境下多进程 DataLoader 和 Mosaic 增强容易带来内存压力，所以采用较稳的配置保证训练完整跑完。从结果看，整体 Precision 为 0.412，Recall 为 0.318，mAP50 为 0.287，mAP50-95 为 0.162。模型已经具备基本检测能力，但 VisDrone 的密集小目标仍然比较困难。比如 car 类 mAP50 可以达到 0.719，但 bicycle 和 awning-tricycle 等小目标更弱，这也解释了后面校园视频中非机动车类别不稳定的问题。

在应用视频部分，我用的是校园道路地面视角视频，而训练集 VisDrone 是航拍视角。由于我没有无人机，所以这里存在明显域差异：拍摄角度、目标尺度、背景纹理、树叶遮挡和阴影都发生了变化。跟踪阶段使用 model.track，并设置 persist=True，让跟踪器在帧间保存状态。只要检测连续，同一个行人或车辆就能在多帧中保持同一个 Tracking ID。遮挡分析中可以看到，目标在遮挡附近会短时丢失，遮挡结束后重新出现；这个片段没有明显 ID switch，说明短遮挡下跟踪器还能缓存轨迹，但检测框本身会中断。

越线计数的逻辑是记录每个 Tracking ID 的中心点在虚拟线的哪一侧。如果同一个 ID 从线的一侧移动到另一侧，并且这个 ID 没有被计数过，就把总数加一。程序维护 previous_side 和 counted_ids，前者保存上一帧所在侧，后者避免同一目标重复计数。最终程序统计到 1 次穿越，而人工观察大约有 3 次。这个偏差主要来自检测漏检、类别突变和轨迹中断：如果目标接近虚拟线时检测框消失，程序就无法同时看到线前和线后的位置；如果 ID 重新生成，也会破坏同一目标的轨迹连续性。

第三部分是 U-Net 分割任务。这个任务要求不使用预训练权重，从零手写 U-Net，并在 Oxford-IIIT Pet 的 trimap 标注上做三分类语义分割。trimap 标注被映射为 0、1、2 三类，图像和 mask 都 resize 到 256×256 。模型结构包含 DoubleConv、Down、Up 和 OutConv。编码器逐层下采样提取语义信息，解码器逐层上采样恢复空间分辨率，而 skip connection 会把浅层细节直接传给对应的解码层，帮助恢复边界和局部位置。

损失函数部分比较了三种配置：Cross-Entropy、Dice Loss 和 CE + Dice。CE 是逐像素分类损失，梯度稳定，但对面积较小的边界类不够友好。Dice Loss 关注预测区域和真实区域的重叠比例，对类别不均衡更敏感。组合损失则把 CE 和 Dice 加起来，希望模型同时学到像素级类别判别和区域重叠质量。代码中先对 logits 做 softmax，再把 mask 转成 one-hot，计算 intersection 和 cardinality，最终得到 Dice Loss；三种实验只需要切换 YAML 里的 `train.loss_type`。

从结果看，三种损失都能收敛，但 CE + Dice 的 Best mIoU 最高，为 0.7703，并且在第 39 个 epoch 达到最佳值；Dice 单独使用为 0.7677，CE 为 0.7632。可视化结果也比较符合数值表现：模型能稳定分出主体和背景，但边界类最难。以 CE + Dice 为例，三类 IoU 分别约为 0.8409、0.9110 和 0.5369，边界类明显更低。这是因为 trimap 的边界通常是一圈很窄的像素带，比例小、位置敏感，稍微错位就会显著影响 IoU。

最后总结一下，本次作业完成了分类、检测跟踪和分割三类视觉任务。任务一说明 ImageNet 预训练对中小规模细粒度分类非常关键；任务二说明检测和跟踪效果会受到域差异、遮挡和小目标的明显影响；任务三说明手写 U-Net 能够有效收敛，并且 CE + Dice 在 trimap 分割上取得了最好的 mIoU。我的汇报到这里结束，欢迎老师批评指正。

重要概念定义

预训练：在大规模数据集上先训练模型，让主干网络获得通用视觉特征。本实验中指 ResNet-18 在 ImageNet 上的初始化权重。

微调：把预训练模型迁移到新任务上继续训练。本实验中是把 ResNet-18 的分类头改成 37 类，并在 Oxford-IIIT Pet 上训练。

backbone learning rate: 主干网络的学习率。由于主干已经经过预训练，通常设置得较小。

classifier learning rate: 新分类层的学习率。由于分类头从随机初始化开始，通常设置得较大。

SE-block: Squeeze-and-Excitation 注意力模块，通过全局平均池化和全连接层生成通道权重，对特征通道进行重新加权。

Precision: 精确率，表示模型预测为真的目标中有多少是真的，公式为 $TP / (TP + FP)$ 。

Recall: 召回率，表示真实目标中有多少被模型找到了，公式为 $TP / (TP + FN)$ 。

IoU (Intersection over Union): 中文叫交并比，注意第一个字母是大写 I，来自 Intersection，不是小写 l。它的公式是“预测区域和真实区域的交集面积 / 预测区域和真实区域的并集面积”。在目标检测中，它衡量预测框和真实框的重合程度；在语义分割中，它衡量某一类预测像素区域和真实像素区域的重合程度。IoU 越接近 1，说明预测越准；越接近 0，说明预测和真实结果重合很少。

mAP50 (mean Average Precision at IoU 0.50): 这是目标检测中常用的综合指标。它先规定当预测框和真实框的 IoU 大于等于 0.5 时，这个检测可以被认为是一次正确检测；然后在每个类别上根据不同置信度阈值计算 AP，也就是 Precision-Recall 曲线下面积；最后对所有类别的 AP 取平均。mAP50 越高，说明模型在“框的位置基本对、类别也判断对”的标准下整体检测能力越好。

mAP50-95: 在 IoU 阈值从 0.50 到 0.95 之间多档计算 AP 后取平均，比 mAP50 更严格。

Tracking ID: 多目标跟踪中为同一目标在连续帧内分配的身份编号。

ID switch: 跟踪过程中同一个真实目标的 Tracking ID 发生改变，或者两个目标的 ID 被错误交换。

mIoU (mean IoU / mean Intersection over Union): 中文叫平均交并比，注意中间也是大写 I，表示它来自 IoU，而不是字母 l。m 表示 mean，也就是平均。它会先对每一个类别分别计算 IoU，比如本实验中的背景、宠物主体和边界三类

各自都有一个 IoU；然后再把这些类别 IoU 求平均，得到 mIoU。相比 Pixel Accuracy，mIoU 不只是看像素总体正确率，也会更关注每一类区域的分割质量，因此对于类别不均衡、边界区域较少的分割任务更有参考价值。

Pixel Accuracy：像素准确率，表示所有像素中被正确分类的比例。

Cross-Entropy Loss / CE：交叉熵损失，在分割中对每个像素做多分类监督。

Dice Loss：基于 Dice 系数的损失，直接衡量预测区域与真实区域的重叠程度，常用于类别不均衡的分割任务。

logits：模型 softmax 之前输出的原始分数，Cross-Entropy 和 Dice 实现通常都从 logits 开始计算。