

计算机视觉 HW3 实验报告

多源 3D 场景融合与 ACT 跨环境泛化

项目	内容
姓名	陈家龙
学号	24300980041
组队情况	单人完成
具体分工	独立完成
报告日期	2026 年 6 月 7 日

提交链接

项目	可公开访问地址
题目一代码仓库	github.com/Loong-C/FDU-Computer-Vision (main/hw3/task1)
题目一模型权重	GitHub Release: cv-hw3-task1-best-weights.tar.gz
题目一漫游视频	GitHub Release: task1-walkthrough.mp4
题目二代码仓库	github.com/Loong-C/FDU-Computer-Vision (main/hw3/task2)
题目二模型权重	FDU GitHub Release: hw3-task2-formal-partial-v1
题目二 SwanLab	swanlab.cn/@Linkukai/hw3-calvin-act
网盘镜像	模型、视频与报告镜像文件夹

提交说明。 题目一包含 2DGS、AIGC 与 Blender 融合流程；题目二包含资源约束下基于官方 CALVIN 帧的 ACT 对比实验。训练曲线由 SwanLab 记录导出。模型权重和视频提供公开下载地址；题目一资产包、漫游视频和题目二权重均提供 FDU GitHub Release，Google Drive 继续作为镜像目录。

摘要

本作业包含两个相互独立但都强调完整实验链路的视觉任务。题目一从真实采集、文本生成和单图生成三种来源构建 3D 资产，使用 2D Gaussian Splatting (2DGS) 重建真实物体与 Mip-NeRF 360 背景，并将异构表示统一为 Mesh 后在 Blender 中完成融合渲染。题目二使用 LeRobot 中的 ACT 策略，在 CALVIN 环境 B 与混合环境 A+B+C 上分别训练模型，再在未见过的环境 D 上比较离线零样本动作误差，并补充 CALVIN simulator rollout 成功率。实验表明：多视角重建在几何可靠性上最强，文本到 3D 输入成本最低，单图到 3D 则在真实外观保持与采集成本之间折中；ACT 的多环境训练虽然提高了同分布验证损失，却使环境 D 的 first-action MAE 和 chunk-action MAE 分别下降 17.0% 和 11.7%。两个策略在 3 条环境 D simulator 五任务序列上的 SR@1-SR@5 均为 0，说明离线动作误差与长时闭环成功率反映的是不同层次的泛化能力。

1 作业目标与实验组织

课程作业包含 3D 视觉场景融合与具身策略泛化两道题。题目一需要处理四类来源不同、原生表示不同的资产，并将其组合为可渲染的统一场景。题目二保持 ACT 网络架构和超参数一致，仅改变训练环境分布，用于观察视觉分布偏移下的零样本行为。

所有长时间实验均由可追踪脚本启动。题目一将 2DGS TensorBoard 标量与 AIGC 训练指标导入 SwanLab 本地运行；题目二在 SwanLab 中记录 Action L1、KL、验证损失、环境 D 动作误差和 simulator rollout 成功率，同时保留 CSV/JSON 备份。报告中的曲线均由记录指标生成。

2 题目一：2DGS 与 AIGC 多源资产融合

2.1 要求拆解与数据准备

题目一要求准备三个独立 3D 物体，并将它们放入同一真实背景：物体 A 必须由手机多视角拍摄、COLMAP 位姿估计和 2DGS 重建得到；物体 B 必须仅由文本 Prompt 驱动 threestudio 与 SDS 优化得到；物体 C 必须由一张真实物体照片经过背景后输入 Magic123；背景场景则来自公开 3D 数据集并使用 2DGS 重建。本实验选择 Mip-NeRF 360 的 counter 场景作为统一环境。

表 1: 题目一数据与预处理。

资产	输入规模	准备过程
物体 A	手机照片 63 张，其中注册 34 张	COLMAP 特征匹配、稀疏重建、去畸变
物体 B	文本 Prompt 1 条	固定产品描述，直接驱动 SDS 优化
物体 C	手机实拍图 1 张，1448 × 1086	棋盘格背景去除、RGBA 前景、MiDaS 深度
背景	counter 多视角图 240 张	选择性下载开源场景，复用相机参数

物体 A 的 COLMAP 稀疏模型最终包含 1527 个稀疏点和 5203 次观测，平均轨迹长度为 3.407335，平均每张图像包含 153.029412 次观测，平均重投影误差为 1.192686 像素。这说明筛选后的 34 个视角具有足够重叠，可用于后续显式表面优化。物体 C 采用药盒作为输入：先得到干净的 alpha 前景，再构建 Magic123 所需的 RGBA 与深度先验。

2.2 真实物体与背景：COLMAP + 2DGS

COLMAP 首先从多视角图像恢复相机内外参与稀疏点云。之后使用 2DGS 将场景表示为一组具有中心、尺度、旋转、颜色、不透明度和球谐系数的二维高斯面片。与体积型 3D Gaussian Splatting 相比，2DGS 更强调表面对齐，因此更适合在重建后提取网格。像素重建损失使用 L1 与 DSSIM 组合：

$$\mathcal{L}_{\text{rgb}} = (1 - \lambda_{\text{dssim}})\mathcal{L}_1 + \lambda_{\text{dssim}}(1 - \text{SSIM}). \quad (1)$$

正式配置中 $\lambda_{\text{dssim}} = 0.2$ 。在第 7000 步后，额外启用 $\lambda_{\text{normal}} = 0.05$ 的法线一致性正则；失真正则权重设为 0。物体 A 使用原始分辨率，背景 counter 使用半分辨率，两者均训练 30000 步。


2.3 文本到 3D: threestudio DreamFusion SDS

物体 B 的 Prompt 为：


A studio product photo of a small red ceramic teapot with a round body, short spout, and curved handle.

threestudio 的 DreamFusion 路线将待优化物体表示为隐式体场，从随机相机渲染图像，并使用 Stable Diffusion 1.5 提供 SDS 梯度。训练过程中无需真实 3D 监督，当


Object A: phone multiview + 2DGS



Object B: text prompt + SDS



Object C: single image + Magic123



Background: Mip-NeRF 360 counter + 2DGS



图 1: 题目一的四类输入与阶段性产物。物体 A 来自真实手机多视角, 物体 B 由文本生成, 物体 C 来自单图, 背景为 Mip-NeRF 360 counter 场景。

前渲染在扩散模型的噪声预测空间内逐渐接近文本条件。简化后的梯度可写为

$$\nabla_{\theta} \mathcal{L}_{\text{SDS}} \approx \mathbb{E}_{t, \epsilon} \left[w(t) (\hat{\epsilon}_{\phi}(x_t; y, t) - \epsilon) \frac{\partial x}{\partial \theta} \right]. \quad (2)$$

本实验训练 10000 步, 随机视角分辨率为 64×64 , 使用 Adam 优化器。正式导出的 OBJ 包含 28180 个顶点和 56536 个三角面。

2.4 单图到 3D: Magic123

物体 C 的单张图像只能约束可见表面, 因此恢复不可见侧面时必须依赖生成先验。本实验先移除棋盘格背景, 通过 alpha 前景避免背景纹理进入重建, 再使用 MiDaS 估计深度。Magic123 的 coarse 阶段同时使用 Stable Diffusion 1.5 的二维语义先验与 Zero123 的新视角先验优化 NeRF; fine 阶段从 coarse 检查点初始化 DMTet, 并输出带纹理 Mesh。受本机 8 GB GPU 与主存约束影响, 本地正式实验采用 coarse 500 步和 fine 500 步; Magic123 参考预算为每阶段 5000 步。最终 OBJ 包含 22860 个顶点和 45730 个三角面。

2.5 异构表示统一与场景融合

四类资产采用不同的原生形式: 2DGS 是显式高斯面片, DreamFusion 与 Magic123 在优化阶段分别使用隐式体场和 NeRF/DMTet。直接在高斯参数层拼接需要

为每种 AIGC 资产重新设计采样、初始化和外观拟合流程, 且不利于稳定控制遮挡和尺度。本实验选择带颜色或纹理的 Mesh 作为交换表示: 物体 A 与背景从 2DGS 通过有界 TSDF 表面提取获得 PLY; 物体 B 与物体 C 从各自生成框架导出 OBJ。

Blender 场景中, 背景保持原尺度; 物体 A、B、C 分别放置在 $(-0.620, 1.750, -0.254)$ 、 $(-0.013, 1.995, -0.306)$ 和 $(0.719, 2.012, -0.315)$, 尺度分别设为 0.10、0.40 和 0.60。相机路径从 counter 的 COLMAP 位姿导出, 最终渲染 180 帧、 640×480 、30 fps 的多视角漫游视频。实现过程分为表示转换和场景编排两个步骤。前一步保证资产可互操作, 后一步用于统一控制遮挡关系、光照和相机运动。

2.6 题目一实验设置

正式实验的设置集中在表 2 中。2DGS 部分沿用官方优化参数, 并分别记录物体 A 与背景场景的验证指标; DreamFusion 与 Magic123 记录实际迭代数、渲染分辨率、优化器和 guidance 权重。后续的验证曲线、三视图比较和耗时统计均对应这一组设置。

题目一融合流程：异构资产先统一为 Mesh，再进入 Blender 渲染



图 2：题目一统一表示与融合流程。不同来源先转换为 Mesh，再在 Blender 中完成尺度、位姿、光照与相机轨迹设置。

2.7 题目一结果与分析

表 3：2DGS 验证指标。

资产	迭代	PSNR (dB)	验证 L1	高斯点数
物体 A	7000	31.8275	0.015616	149488
物体 A	30000	33.5198	0.011289	212465
counter	7000	28.0689	0.021551	482345
counter	30000	29.9138	0.016986	533358

物体 A 从第 7000 步到第 30000 步的 PSNR 提升 1.6923 dB，验证 L1 下降约 27.7%；背景 PSNR 提升 1.8449 dB，验证 L1 下降约 21.2%。背景的点数明显更多，因为厨房台面包含更多遮挡、反光与细粒度结构。高斯点数增长与验证指标改善同时出现，表明增密过程补充了有效的表面细节。

物体 B 的 SDS 曲线存在高频波动，这是随机相机、随机噪声步与扩散先验共同作用的结果。最终预览能够辨认红色陶瓷茶壶的壶盖、短壶嘴、圆形壶身和弯曲把手，说明文本语义已经转化为可用类别形状；但局部几何缺少真实观测作为验证依据。物体 C 的正面受到输入照片约束，药盒外观得以保留；侧面和背面主要依靠生成先验补全，其几何真实性相对有限。

2.7.1 代表性三视图与还原质量分析

图 5 从三个方向展示三种方法的输出。物体 A 使用 2DGS 导出的 `fuse_post.ply`，裁剪出手办主体后进行正交渲染。原始 TSDF Mesh 还包含少量邻近地面残片，裁剪时保留了贴近主体的表面提取结果，便于观察真实的网格质量。物体 B 选取 DreamFusion 环绕序列 0/30/60；物体 C 选取 Magic123 Lambertian 环绕序列

0000/0025/0050。这些视图用于比较外观、轮廓和跨视角稳定性，不用于精确尺寸测量。

物体 A：真实多视角重建。PLY Mesh 的正面仍能辨认发型、蝴蝶结、面部、服装和腿部，侧面与背面也保留了马尾的主要轮廓。同时，网格表面比 2DGS 新视角渲染更粗糙，马尾、裙摆和腿部附近存在局部粘连，侧后方还能看到少量 TSDF 残片。手机拍摄中的视角覆盖不均、地砖反光和细小结构遮挡都会影响表面提取。多视角路线具备较好的真实外观还原能力，导出 Mesh 的质量仍需要结合后续清理流程评估。

物体 B：文本到 3D。茶壶在三个环绕视角中始终保留圆形壶身、壶盖、壶嘴和把手，类别语义和整体拓扑较稳定；这说明 SDS 优化能够从纯文本产生可用于融合渲染的完整虚拟资产。局部细节仍不够稳定：壶嘴与把手的相对投影会随角度变化，表面还存在少量噪点，且没有真实茶壶作为几何参照。这一结果适合作为符合 Prompt 的虚拟资产，不宜用于现实对象的精确测量。

物体 C：单图到 3D。药盒正面仍能保留白蓝配色、文字区域和盒装轮廓；转向侧面后，未在输入照片中出现的区域开始发生纹理拉伸和几何鼓包；到背向视角时，规则长方体外形明显退化。该现象直接展示了单图重建的核心歧义：可见面由照片提供强约束，不可见面只能依赖生成先验补全。受本实验 coarse/fine 优化预算限制，Magic123 结果适合在融合场景中提供身份线索，但不适合需要精确侧后面结构的应用。

2.7.2 几何准确度、纹理细节与计算耗时对比

从几何准确度看，三种方法的差异主要来自输入信息量。多视角重建有真实图像和相机位姿作为约束，物体 A 的 34 个注册视角形成了可闭合的稀疏模型，平均重投影误差为 1.192686 像素；随后 2DGS 在 30000 步达到 33.5198 dB PSNR 和 0.011289 验证 L1。图 5 中手办

表 2: 题目一主要超参数。2DGS 使用官方参数组; Magic123 的本地正式预算根据硬件约束调整。

阶段	迭代 / 分辨率	优化器	关键参数	损失与监控指标
物体 A 2DGS	30000 / 原始尺寸	官方 Adam	2DGS 位置 LR $1.6 \times 10^{-4} \rightarrow 1.6 \times 10^{-6}$; 特征 LR 0.0025; 不透明度 LR 0.05; 尺度 LR 0.005; 旋转 LR 0.001	L1 + DSSIM; 法线正则 0.05; PSNR、验证 L1、高斯点数
背景 counter 2DGS	30000 / half	同上	与物体 A 相同; 半分辨率降低显存与时间成本	L1 + DSSIM; 法线正则 0.05; PSNR、验证 L1、高斯点数
物体 B DreamFusion	10000 / 64×64	Adam	batch size 1; geometry LR 0.01; background LR 0.001; guidance scale 100; mixed precision	SDS 1.0; sparsity 1.0; 方向正则调度; SDS 曲线
物体 C Magic123 coarse	500 / 128×128	Adam	SD / Zero123 guidance scale 100 / 5; $\lambda_{\text{guidance}}=[1.0, 40]$	总损失与两个 guidance 分量
物体 C Magic123 fine	500 / DMTet	Adam	coarse checkpoint 初始化; $\lambda_{\text{guidance}}=[1e-3, 0.01]$	总损失、guidance 分量、最终纹理 Mesh

的正面、侧面和背面都能保持同一主体轮廓,这一点优于另外两种生成路线。导出 Mesh 时仍能看到局部粘连和 TSDF 残片,说明多视角结果在真实还原上最可靠,但网格化质量还会受到拍摄覆盖、反光和表面细节尺度的影响。文本生成的物体 B 没有真实对象作为几何目标,它得到的是符合 Prompt 的类别形状:壶身、壶盖、壶嘴和把手在环绕视图中基本稳定,局部比例和连接处则更依赖扩散先验。单图生成的物体 C 介于两者之间,正面由照片直接约束,侧面和背面需要推断;三视图中药盒背向视角的形变最明显,也最能体现单图输入的几何不确定性。

纹理细节方面,多视角重建保留了实拍手办的发色、服装颜色和整体材质关系,细小边缘处会因为 Mesh 提取而变得粗糙。文本生成路线的纹理受 Prompt 控制,红色陶瓷材质整体一致,适合作为风格明确的虚拟道具;它无法保证与某个现实茶壶完全对应。单图生成路线在药盒正面表现最好,文字区域、蓝白配色和盒面分区都能保留下来;转到侧后方后,纹理开始拉伸并出现补全痕迹。由此看,单图方法适合保存可见面的身份特征,完整纹理一致性仍弱于多视角实拍。

计算耗时与输入成本也需要分开看。图 6 和表 4 显示,物体 A 的 COLMAP 后 2DGS 用时 4855.77 s,约 1.35 h;这还不包含手机环绕拍摄、筛图和位姿检查的人力时间。物体 B 的 DreamFusion 训练与 OBJ 导出合计 3659.68 s,输入只需要一条文本,是三种物体生成路线中前期准备最轻的一种。物体 C 的 Magic123 coarse 与 fine 合计 33039.31 s,约 9.18 h,是本实验中最慢的物体生成流程;它需要同时利用二维扩散先验和新视角先验,且本

机预算已经低于论文推荐的完整迭代数。综合三视图和耗时曲线,三种路线的选择取决于任务目标:需要真实对象还原时优先多视角重建,需要快速补充语义资产时优先文本生成,只有单张照片且希望保留对象正面特征时可以采用单图生成。仅看一张正面预览会高估生成式 3D 的几何质量,环绕视图更能反映最终融合时的可用性。

表 4: 题目一正式阶段耗时。

阶段	秒	约合时间
物体 A: COLMAP 后 2DGS	4855.77	1.35 h
背景: counter 2DGS	1368.52	0.38 h
物体 B: DreamFusion 训练	3624.22	1.01 h
物体 B: OBJ 导出	35.46	0.01 h
物体 C: Magic123 coarse	29639.49	8.23 h
物体 C: Magic123 fine	3399.82	0.94 h
融合视频渲染	5599.89	1.56 h

综合来看,三条路线各有适用范围。多视角重建的输入成本最高,但可解释性也最强;文本到 3D 适合低成本资产扩展;单图到 3D 位于二者之间。统一为 Mesh 后,Blender 能直接处理尺度、遮挡和相机运动,但代价是无法继续享受 2DGS 原生实时渲染的全部优势。




图 3: 由 SwanLab 记录指标导出的 2DGS 验证曲线。物体 A 与背景在 30000 步时均优于 7000 步检查点：PSNR 上升且 L1 下降。




图 4: 由 SwanLab 记录指标导出的 AIGC 优化曲线。左：物体 B 的 SDS 原始值与移动平均；右：物体 C 的 Magic123 总损失与 guidance 分量。生成式优化具有显著随机波动，因此曲线主要用于观察训练稳定性与阶段完成情况。

表 5: 三种 3D 资产构建路线的对比。

路线	几何准确度	纹理细节	计算耗时与输入成本	适用边界
真实多视角重建	观测覆盖充分时最可靠；可用 COLMAP 重投影误差与 2DGS 验证指标量化	能保留实拍细节，但弱纹理、反光和遮挡仍会降低稳定性	需要环绕拍摄和位姿恢复；本实验 2DGS 训练 4855.77 s	适合能够重新拍摄、重视真实几何的对象
文本到 3D	可得到清晰类别轮廓，但局部比例与细节受扩散先验影响，缺少真实几何监督	外观可由 Prompt 控制，但不保证对应现实中的某个具体物体	输入成本最低，仅需文本；本实验训练与导出合计 3659.68 s	适合快速生成虚拟装饰物或原型资产
单图到 3D	正面由实拍图约束，侧面后面依赖新视角先验补全，不可见区域存在歧义	正面纹理保持较好，侧面后面纹理的真实性较弱	采集简单但优化最慢；本实验 coarse + fine 合计 33039.31 s	适合只有单张图、又希望保留对象身份线索的场景

题目一正式输出的三视角代表性对比




图 5：题目一三种 3D 构建方法的代表性三视图。每行对应一种方法，每列对应逐步变化的观察视角。上：从 2DGS 导出 PLY 中裁剪并渲染的手办 Mesh；中：文本 Prompt 驱动 DreamFusion 生成的红色陶瓷茶壶；下：单张药盒照片驱动 Magic123 得到的 3D 资产。




图 6：左：最终融合漫游视频的代表帧。右：题目一各主要阶段的端到端耗时。

3 题目二：LeRobot ACT 跨环境泛化

3.1 任务定义、数据规模与评估边界

题目二要求在 CALVIN 数据集上比较两个 ACT 策略：基线仅使用环境 B 训练；联合模型使用环境 A、B、C 混合训练。二者必须采用相同网络结构和超参数，随后在训练阶段完全不可见的环境 D 上进行 zero-shot 评估。本实验将 D 环境 zero-shot 分成两个层级：第一层在官方 D validation 抽样帧上计算 first-action MAE 与 chunk-action MAE；第二层把两个最佳 checkpoint 包装成 CALVIN `reset/step` 策略，在 `calvin_scene_D simulator` 中执行闭环 rollout。rollout 使用官方任务 `oracle`、`validation language annotations`、3 条自动生成的五任务序列，每个子任务最多执行 360 步。该设置能够验证模型是否能部署到未见环境 D，但规模仍小于 CALVIN 完整长时评测协议。

官方 CALVIN 元数据给出的训练帧范围如表 6。完整 A+B+C 压缩包约 517 GB，D 环境压缩包约 166 GB。为在本机完成可复现实验，项目实现 HTTP Range 下载器：从官方压缩包中均匀抽取连续窗口、验证 CRC，并

保持原始目录结构，不需要下载完整归档。

表 6: CALVIN 官方训练帧范围。

环境	官方闭区间
B	0–598909
C	598910–1191338
A	1191339–1795044

表 7: 题目二资源约束下的正式子集协议。

用途	选取帧数	本地数据量	处理后样本数
A+B+C 训练源数据	2304	634.01 MiB	691 训练 / 77 验证
B-only 训练源数据	768	包含于上行	230 训练 / 26 验证
D 环境 zero-shot 评估	768	212.78 MiB	768 离线帧；3 条 rollout 序列

本地实际使用的 CALVIN 帧数据合计 887929630 bytes，约 846.8 MiB，其中 A+B+C 训练源数据约 634.01 MiB，D 环境离线评估数据约 212.78 MiB。另有约 287.97 MiB 的 `.cache` 索引文件，用于定位远程 ZIP 中的条目。训练数据使用 stride 3 与 90/10 训练验证划分。B-only 与 A+B+C 模型的样本数量不同，联合训练模型能够接触三种场景的视觉多样性；二者的网络、优化器、步数和评估脚本完全一致，因此差异主要来自训练环境分布变化。

3.2 ACT 策略与动作分块机制

ACT (Action Chunking with Transformers) 根据当前图像和机器人状态一次预测未来 K 步动作块：

$$\hat{\mathbf{a}}_{t:t+K-1} = \pi_{\theta}(\mathbf{o}_t, \mathbf{s}_t). \quad (3)$$

本实验使用 LeRobot v0.5.1 中的 `ACTPolicy`，输入为 128×128 RGB 图像和 15 维状态，输出为 7 维动作，动作块长度 $K = 20$ 。模型包含 ResNet-18 视觉骨干、Transformer 编码器与解码器，以及条件 VAE 潜变量。训练目标可概括为

$$\mathcal{L}_{\text{ACT}} = \mathcal{L}_1(\hat{\mathbf{a}}, \mathbf{a}) + \lambda_{\text{KL}} \mathcal{L}_{\text{KL}}, \quad \lambda_{\text{KL}} = 10. \quad (4)$$

动作分块对视觉偏移具有两面性。一方面，一次预测一段动作可以减少单帧噪声引起的控制抖动，并让轨迹更连贯；另一方面，若视觉表征在新环境中发生系统性偏差，较长 horizon 也会累积不确定性。因此，本实验同时报告 first-action MAE 与 chunk-action MAE：前者反映立即决策质量，后者更严格地反映整段预测的鲁棒性。

表 8: 题目二 ACT 正式实验超参数。两个训练条件完全一致，仅训练环境不同。

项目	取值	项目	取值	说明
视觉骨干	ResNet-18	图像尺寸	128×128	不加载预训练 backbone 权重
Transformer 维度	256	attention heads	8	feedforward 维度 1024
编码器 / 解码器层数	3 / 1	动作块长度	20	推理时输出 20 步动作
状态 / 动作维度	15 / 7	VAE latent 维度	32	VAE 编码器 2 层, KL 权重 10
优化器	AdamW	学习率	1×10^{-5}	backbone 使用相同学习率
权重衰减	1×10^{-4}	batch size	4	AMP 开启, 梯度裁剪范数 10
训练步数	5000	验证间隔	250	每次验证 30 batches
设备	RTX 4060 Ti	显存	8 GB	Windows 本地 CUDA 环境




图 7: 由 SwanLab 记录指标导出的 ACT 训练 Action L1 与 held-out 验证曲线。A+B+C 联合模型面对更复杂的视觉分布，因此验证损失更高；两个条件均呈下降趋势。

3.3 题目二实验设置

3.4 收敛情况、动作误差与 simulator rollout

表 9: ACT 正式实验结果。MAE 越低越好。

训练环境	验证 L1	D first-action MAE	D chunk MAE
B-only	0.324629	0.226251	0.259475
A+B+C	0.386954	0.187712	0.229145




图 8: 环境 D 抽样帧上的离线 zero-shot 动作误差。与 B-only 相比, A+B+C 联合训练使 first-action MAE 下降 17.0%, chunk-action MAE 下降 11.7%。

3.5 现象分析：视觉偏移与动作分块

表 9 中最值得注意的现象是：A+B+C 模型的 held-out 验证 L1 为 0.386954，高于 B-only 的 0.324629，但它在未见环境 D 上的误差更低。B-only 验证集仍来自单

表 10: 环境 D simulator rollout 结果。每个模型评估 3 条五任务序列，每个子任务最多 360 步。

训练环境	序列数	平均完成子任务数	SR@1	SR@2	SR@3	SR@4	SR@5	记录位置
B-only	3	0.0 / 5	0.0	0.0	0.0	0.0	0.0	对应 rollout 输出目录中的 metrics JSON
A+B+C	3	0.0 / 5	0.0	0.0	0.0	0.0	0.0	对应 rollout 输出目录中的 metrics JSON

一环境 B，视觉分布窄，模型更容易拟合；联合模型需要同时处理 A、B、C 中的外观变化，优化问题更难，因此同分布验证误差较高。然而，这种训练阶段的视觉多样性减少了模型对环境 B 背景细节的依赖，使它迁移到 D 时更加稳健。

first-action MAE 的改善幅度为 17.0%，而 chunk-action MAE 的改善幅度为 11.7%。后者较小，说明在视觉分布偏移下，长 horizon 预测仍会累积不确定性。chunk MAE 同样下降，表明多环境训练同时改善了立即决策和整段 20 步预测。动作分块为短期轨迹提供时间一致性，多环境视觉训练则降低了错误视觉线索对整个动作块的传播。

表 10 给出的 simulator rollout 结果更严格。两个模型都能加载到 CALVIN D 场景中并完成 `reset/step` 闭环调用，说明 zero-shot 部署链路已经打通；但 3 条五任务序列的 SR@1–SR@5 均为 0。这个结果与离线 action-error 的改善并不矛盾。离线 MAE 衡量的是给定一帧观测时预测动作与专家动作的平均距离，数值下降说明模型在 D 环境的局部动作回归更接近数据分布。CALVIN rollout 成功率衡量的是长时闭环任务：策略必须根据当前图像、状态和任务序列连续推动环境变化，任一早期子任务失败都会使后续任务无法继续计入。

本实验使用的 ACT 输入为图像和机器人状态，没有显式语言指令输入；rollout adapter 会接收官方 validation annotations，但模型内部并不使用语言条件。因此，模型更接近一个从观测到动作块的模仿策略，尚未具备完整语言条件长时任务策略的输入结构。动作分块在这种闭环评估中也会放大偏差：一旦某次观测产生了偏离目标的 20 步动作块，错误会在一段时间内连续作用到环境，随后再用已经偏移的状态预测下一个动作块。多环境训练能降低视觉偏移造成的局部动作误差，但在小规模数据、无语言条件和长时任务链条同时存在时，还不足以把这种局部改善转化为非零成功率。

3.6 题目二局限性

题目二使用官方 CALVIN 帧的均匀抽样子集，覆盖 846.8 MiB 本地帧数据，未使用完整的 517 GB / 166 GB 数据归档。simulator rollout 已经完成，但只评估了 3 条五任务序列，远小于完整 CALVIN 长时 benchmark 的规模；因此成功率只能作为小规模部署验证结果，而不能代表充分训练后的最终任务能力。离线 action-error 可以衡量模型输出动作与数据集中专家动作的接近程度，也能反映一定的跨环境泛化差异；rollout success 则进一步考察闭环执行、误差累积和任务链条恢复能力。因此，本实验结论限定在报告所述资源约束协议内：多环境联合训练提升了未见环境 D 的离线动作泛化，但在当前小规模 simulator rollout 中尚未产生可统计的成功子任务。

4 复现、SwanLab 与交付物

4.1 SwanLab 记录

表 11: 实验记录与公开链接。

项目	记录方式或链接
题目一 2DGS / DreamFusion / Magic123	SwanLab local runs; 报告图由记录标量导出。本地查看命令: <code>swanlab watch hw3/task1/swanlog</code>
题目二项目页	https://swanlab.cn/@Linkukai/hw3-calvin-act
题目二 B-only 训练	https://swanlab.cn/@Linkukai/hw3-calvin-act/runs/y34dmlyk6ol06me1flig0
题目二 A+B+C 训练	https://swanlab.cn/@Linkukai/hw3-calvin-act/runs/t3kfag5dsiipp3wwxy4te
题目二 B-only → D 评估	https://swanlab.cn/@Linkukai/hw3-calvin-act/runs/b1hdsdo4vgrodwkk3syr7
题目二 A+B+C → D 评估	https://swanlab.cn/@Linkukai/hw3-calvin-act/runs/5ooypxeqhgp4xja928tpk
题目二 B-only → D rollout	https://swanlab.cn/@Linkukai/hw3-calvin-act/runs/kcbgr0rmn3jokevjmxlyj
题目二 A+B+C → D rollout	https://swanlab.cn/@Linkukai/hw3-calvin-act/runs/mqrmkx48ojvthl5gm0u2y

4.2 关键复现入口

题目一与题目二均整理在统一仓库 <https://github.com/Loong-C/FDU-Computer-Vision> 的 `main/hw3` 路径下, 分别位于 `hw3/task1` 与 `hw3/task2`。两个目录均提供 README、环境依赖、数据准备说明、训练命令与测试命令。下面仅列出主入口; 完整命令、兼容性说明与缓存设置见对应目录 README。

Listing 1: 题目一主要复现入口。

```
# 物体 A 与背景: COLMAP + 2DGS
bash scripts/prepare_colmap_object_a.sh --force
bash scripts/train_2dgs_object_a.sh
bash scripts/train_2dgs_background.sh

# 文本到 3D 与单图到 3D
MODE=full bash scripts/generate_text3d_object_b.sh
MODE=full STAGE=coarse bash scripts/generate_image3d_object_c.sh
MODE=full STAGE=fine bash scripts/generate_image3d_object_c.sh

# 统一 Mesh 后融合渲染
MODE=formal bash scripts/render_fusion_tracked.sh
```

Listing 2: 题目二主要复现入口 (PowerShell)。

```
.\scripts\bootstrap.ps1
.\scripts\run_partial_formal.ps1
.\scripts\bootstrap.ps1 -WithCalvinRollout
.\scripts\run_zero_shot_d_rollout.ps1 `
  -MaxSequences 3 `
  -EpisodeLength 360 `
  -Device cuda
```

4.3 公开下载与校验

表 12: 公开交付物。题目一与题目二均使用 FDU 仓库 GitHub Release, Google Drive 作为镜像。

交付物	大小	下载地址或 SHA256
题目一最佳资产包	274591842 bytes	https://github.com/Loong-C/FDU-Computer-Vision/releases/download/hw3-task1-weights/cv-hw3-task1-best-weights.tar.gz
题目一漫游视频	1545398 bytes	https://github.com/Loong-C/FDU-Computer-Vision/releases/download/hw3-task1-weights/task1-walkthrough.mp4
题目一资产包 SHA256	–	4667c06b2e05b4a345f99ae5ee4c2875caaad2f995ad77c6ea813814046ccaec
题目二 B-only 最佳权重	196370804 bytes	GitHub Release 下载; 58afae052ef2ce029f92c9258e1b5012a9c44fac5753c1c8330b7d196a976131
题目二 A+B+C 最佳权重	196370804 bytes	GitHub Release 下载; 1b1f182e61026929f0a5ffdc5ee096d15e4771febd111d9efe3d88bc4a9adcff
题目二权重 Release	–	FDU GitHub Release 页面
Google Drive 镜像目录	–	Google Drive 镜像文件夹

5 结论

题目一完成了从真实采集、文本生成、单图生成到真实场景融合的完整链路。实验说明，多视角重建、文本到 3D 和单图到 3D 各自适合不同的信息条件；当原生表示不一致时，将资产转换为 Mesh 再进入 Blender 是一种工程上直接、稳定且便于控制的统一方案。题目二完成了相同 ACT 架构下的训练分布对照：A+B+C 联合训练虽然增加了拟合难度，却降低了未见环境 D 上的离线动作误差。进一步的 CALVIN D simulator rollout 表明，两个模型都可以在未见 D 场景中完成闭环部署，但当前 3 条五任务序列的成功率仍为 0。该现象支持视觉多样性训练有助于局部动作泛化，同时也说明动作分块、语言条件缺失和长时误差累积仍是闭环成功率的主要限制。

参考文献

- [1] B. Huang et al. 2D Gaussian Splatting for Geometrically Accurate Radiance Fields. SIGGRAPH 2024. <https://arxiv.org/abs/2403.17888>
- [2] B. Poole et al. DreamFusion: Text-to-3D using 2D Diffusion. ICLR 2023. <https://arxiv.org/abs/2209.14988>
- [3] G. Qian et al. Magic123: One Image to High-Quality 3D Object Generation Using Both 2D and 3D Diffusion Priors. ICLR 2024. <https://arxiv.org/abs/2306.17843>
- [4] J. T. Barron et al. Mip-NeRF 360: Unbounded Anti-Aliased Neural Radiance Fields. CVPR 2022. <https://arxiv.org/abs/2111.12077>
- [5] O. Mees et al. CALVIN: A Benchmark for Language-Conditioned Policy Learning for Long-Horizon Robot Manipulation Tasks. IEEE RA-L 2022. <https://arxiv.org/abs/2112.03227>
- [6] T. Z. Zhao et al. Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware. RSS 2023. <https://arxiv.org/abs/2304.13705>
- [7] Hugging Face. LeRobot: State-of-the-art Machine Learning for Real-World Robotics in Pytorch. <https://github.com/huggingface/lerobot>